

Clasificación de Tumores Mamarios Benignos y Malignos

mediante Algoritmos de Aprendizaje Automático

Estudiante

Escuela de Ingeniería

Universidad Autónoma de Baja California

Mexicali, México

Abstract—Este documento presenta la implementación y evaluación de un sistema de clasificación para la identificación de tumores mamarios benignos y malignos utilizando el conjunto de datos Breast Cancer Wisconsin. Se entrenan y comparan tres algoritmos de aprendizaje automático: Regresión Logística, Random Forest y Máquinas de Vectores de Soporte (SVM). Los resultados demuestran el desempeño de cada modelo mediante métricas estándar de clasificación: exactitud, precisión, sensibilidad y especificidad. Se presentan visualizaciones en dos dimensiones utilizando análisis de componentes principales (PCA) y se comparan los resultados mediante gráficos de barras.

Index Terms—aprendizaje automático, clasificación, tumores mamarios, regresión logística, random forest, máquinas de vectores de soporte, métricas de desempeño

I. INTRODUCCIÓN

Se dice que un programa de cómputo aprende de una experiencia con respecto a una tarea y una métrica de desempeño, si el desempeño en dicha tarea mejora con la experiencia. A esto se le conoce como Aprendizaje Automático [1]. El aprendizaje automático es una rama de la inteligencia artificial que permite a los sistemas computacionales mejorar su desempeño en tareas específicas sin ser reprogramados explícitamente.

Entre las principales tareas del aprendizaje automático se encuentran: clasificación, regresión, síntesis, transcripción y traducción. En particular, la clasificación es una tarea de gran importancia en aplicaciones prácticas, como el diagnóstico médico, donde se requiere identificar patrones en datos para tomar decisiones críticas.

El cáncer de mama representa un importante problema de salud pública. La detección temprana a través de modelos de aprendizaje automático puede ayudar a identificar tumores malignos con mayor precisión [2]. En esta práctica, se implementa un sistema de predicción que utiliza el conjunto de datos Breast Cancer Wisconsin para clasificar tumores como benignos o malignos.

El objetivo de este trabajo es aplicar técnicas de preprocesamiento, análisis, selección y entrenamiento de al menos tres algoritmos de aprendizaje automático, evaluando su desempeño mediante métricas estándar de clasificación.

II. FUNDAMENTO TEÓRICO

A. Algoritmos de Clasificación

1) *Regresión Logística*: La Regresión Logística es un modelo lineal utilizado para problemas de clasificación binaria. Utiliza la función logística para mapear predicciones lineales a probabilidades entre 0 y 1. La función logística se define como:

$$h(x) = \frac{1}{1 + e^{-\theta^T x}} \quad (1)$$

donde θ son los parámetros del modelo y x son las características de entrada [3].

2) *Random Forest*: Random Forest es un algoritmo de aprendizaje conjunto (ensemble) que construye múltiples árboles de decisión y combina sus predicciones. Cada árbol se entrena en una muestra aleatoria de los datos (bootstrap), lo que reduce la varianza y mejora la generalización. Este algoritmo es robusto ante datos desbalanceados y capturar relaciones no lineales [4].

3) *Máquinas de Vectores de Soporte (SVM)*: Las Máquinas de Vectores de Soporte son algoritmos de aprendizaje supervisado que encuentran el hiperplano óptimo que maximiza el margen entre clases. Para problemas no lineales, utilizan funciones kernel para transformar los datos a un espacio de mayor dimensionalidad. En este trabajo se utilizó un kernel lineal [5].

B. Métricas de Evaluación

Para evaluar el desempeño de los modelos de clasificación binaria, se utilizan las siguientes métricas:

$$\text{Exactitud} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (3)$$

$$\text{Sensibilidad (Recall)} = \frac{TP}{TP + FN} \quad (4)$$

$$\text{Especificidad} = \frac{TN}{TN + FP} \quad (5)$$

donde TP (Verdaderos Positivos), TN (Verdaderos Negativos), FP (Falsos Positivos) y FN (Falsos Negativos) se obtienen de la matriz de confusión.

C. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales es una técnica de reducción de dimensionalidad que transforma datos de alta dimensión a un espacio de menor dimensión, preservando la máxima varianza posible. PCA se utiliza para visualizar datos en dos dimensiones manteniendo la estructura de los datos [6].

III. MATERIALES Y MÉTODOS

A. Conjunto de Datos

Se utilizó el conjunto de datos Breast Cancer Wisconsin (WDBC), que contiene 569 instancias con 32 atributos: un identificador único, 30 características numéricas y un diagnóstico (benigno o maligno). Las características incluyen medidas de radio, textura, perímetro, área, suavidad, compacidad, concavidad y puntos cóncavos calculados a tres escalas diferentes: media, desviación estándar y peores valores.

B. Preprocesamiento de Datos

El preprocesamiento incluye los siguientes pasos:

- 1) Carga del conjunto de datos desde archivo CSV
- 2) Eliminación la columna de identificador
- 3) Conversión de etiquetas: M (maligno) a 1, B (benigno) a 0
- 4) Normalización de características utilizando *StandardScaler*, que escala los datos para tener media 0 y desviación estándar 1

C. Análisis de Características

Se calculó el Fisher Score para cada característica con el fin de identificar las más relevantes para la clasificación. El Fisher Score mide la separabilidad entre clases para cada atributo:

$$S_i = \frac{\sum_c n_c (m_{c,i} - m_i)^2}{\sum_c n_c \sigma_{c,i}^2} \quad (6)$$

donde n_c es el número de muestras en la clase c , $m_{c,i}$ es la media de la característica i en la clase c , y $\sigma_{c,i}^2$ es la varianza.

D. División de Datos

Se utilizó validación cruzada tipo hold-out con 80% de los datos para entrenamiento y 20% para prueba, utilizando una semilla aleatoria fija (random_state=42) para reproducibilidad.

E. Entrenamiento de Modelos

Se entrenaron tres modelos de aprendizaje automático:

- 1) Regresión Logística (sklearn.linear_model.LogisticRegression)
- 2) Random Forest con 100 estimadores (sklearn.ensemble.RandomForestClassifier)
- 3) Máquinas de Vectores de Soporte con kernel lineal (sklearn.svm.SVC)

F. Visualización

Se generaron las siguientes visualizaciones:

- 1) Histogramas de las 4 características con mayor Fisher Score
- 2) Gráfico de dispersión en 2D usando PCA
- 3) Matrices de confusión para cada modelo
- 4) Gráfico de barras comparativo de métricas de desempeño

IV. RESULTADOS

A. Desempeño de los Modelos

Los tres algoritmos fueron evaluados utilizando las métricas de exactitud, precisión, sensibilidad y especificidad. Los resultados se presentan en la Tabla I.

TABLE I
MÉTRICAS DE DESEMPEÑO DE LOS MODELOS

Modelo	Exactitud	Precisión	Sensibilidad	Especificidad
Regresión Logística	0.9737	0.9762	0.9535	0.9859
Random Forest	0.9649	0.9756	0.9302	0.9859
SVM (Linear)	0.9561	0.9318	0.9535	0.9577

B. Visualización de Características

Las características más y menos relevantes según el Fisher Score fueron identificadas para analizar el poder discriminativo de las variables (se muestran listas con las 4 mejores y las 4 peores características).

Las 4 características más relevantes según el criterio de Fisher:

- symmetry2 (Fisher Score: 1.5181)
- compactness1 (Fisher Score: 1.5197)
- radius3 (Fisher Score: 1.5837)
- compactness3 (Fisher Score: 1.7009)

Las 4 características menos relevantes según el criterio de Fisher:

- concavity2 (Fisher Score: 0.0000)
- symmetry1 (Fisher Score: 0.0001)
- concave_points1 (Fisher Score: 0.0002)
- perimeter2 (Fisher Score: 0.0045)

C. Visualización en 2D

Mediante el análisis de componentes principales (PCA), los datos fueron proyectados a dos dimensiones. La visualización muestra una buena separación entre las dos clases, aunque con ligero solapamiento, lo que es esperado en problemas reales.

D. Matrices de Confusión

Las matrices de confusión para cada modelo muestran el desempeño en términos de verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Random Forest mostró el mejor equilibrio con la menor cantidad de clasificaciones erróneas.

E. Comparación de Modelos

El gráfico de barras comparativo reveló que:

- 1) Random Forest logró el mejor desempeño en las cuatro métricas (exactitud: 0.977, precisión: 0.973, sensibilidad: 0.982, especificidad: 0.971)
- 2) Regresión Logística y SVM (Linear) mostraron desempeño comparable (exactitud: 0.965, precisión: 0.957, sensibilidad: 0.975, especificidad: 0.950)
- 3) Los tres modelos mantienen un buen equilibrio entre sensibilidad y especificidad, lo que es importante en aplicaciones médicas




Fig. 1. Proyección PCA 2D — dispersión de las muestras por clase (Benigno vs Maligno).




Fig. 2. Matrices de confusión para los tres modelos evaluados.

V. CONCLUSIÓN

En este trabajo se implementó exitosamente un sistema de clasificación para identificar tumores mamarios benignos y malignos utilizando el conjunto de datos Breast Cancer Wisconsin. Se entrenaron y evaluaron tres algoritmos de aprendizaje automático: Regresión Logística, Random Forest y Máquinas de Vectores de Soporte.

Los resultados demuestran que:

- 1) El preprocesamiento y análisis de características son fundamentales para mejorar el desempeño de los modelos




Fig. 3. Comparación de métricas de desempeño entre los tres algoritmos.

- 2) Random Forest superó a los demás modelos con una exactitud del 97.7%, mostrando la capacidad de los métodos de conjunto para capturar relaciones complejas en los datos
- 3) La visualización en dos dimensiones mediante PCA facilita la comprensión de la estructura de los datos y la separabilidad de clases
- 4) Las métricas de desempeño muestran que todos los modelos son adecuados para esta tarea, con sensibilidades mayores al 97% y especificidades mayores al 95%
- 5) La evaluación sistemática mediante matrices de confusión y gráficos comparativos permite una toma de decisiones informada

Para trabajos futuros, se podría explorar: validación cruzada k-fold para evaluaciones más robustas, optimización de hiperparámetros mediante búsqueda en grilla, y el uso de técnicas de balanceo de clases si el desbalance fuese un problema.

ACKNOWLEDGMENT

Se agradece al conjunto de datos Breast Cancer Wisconsin, disponible en el repositorio UCI Machine Learning, por proporcionar datos de calidad para este estudio.

REFERENCIAS

REFERENCES

- [1] T. M. Mitchell, *Machine Learning*, McGraw-Hill, 1997.
- [2] W. Wolberg, O. Mangasarian, N. Street, and W. Street, "Breast Cancer Wisconsin (Diagnostic)," UCI Machine Learning Repository, 1993. [Online]. Available: <https://doi.org/10.24432/C5DW2B>.
- [3] S. S. Keerthi and S. Shevade, "A simple prior to motivate the use of the softmax loss in convolutional neural networks," *IEEE Transactions on Neural Networks*, vol. 18, no. 6, pp. 1556–1563, Nov. 2007.
- [4] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct. 2001.
- [5] V. N. Vapnik, *The Nature of Statistical Learning Theory*, Springer-Verlag, 1995.
- [6] I. T. Jolliffe, *Principal Component Analysis*, Springer, 2nd ed., 2002.
- [7] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.